P13 Bottleneck Missions 1 et 2

Amélioration du projet P6 et préparation du portfolio professionnel

Mon objectif est de rendre l'analyse des produits plus facile à relancer et à vérifier, sans modifier les fichiers d'origine.

Ce que j'ai réalisé

- J'ai repris le notebook P6 et construit un traitement local des fichiers ERP, liaison et Web.
- Le traitement vérifie les fichiers, rapproche les produits et produit un rapport avec les points à examiner.
- J'ai comparé plusieurs façons de traiter les identifiants et documenté les écarts avec les anciens exports.
- J'ai aussi préparé le portfolio, une veille technique et un guide pour expliquer les alertes.

Les principaux chiffres du lot étudié

Élément	Résultat vérifié
Fichiers reçus	ERP : 825 lignes ; liaison : 825 lignes ; Web : 1 513 lignes.
Exports P6	df_final : 714 produits ; df_clean : 713 après le filtre de marge positive.
Chiffre d'affaires recalculé	143 324,10 € avec la formule du P6, sur les produits au stock positif ou nul.
Rapprochement	91 id_web absents dans la liaison ; 111 produits ERP/liaison sans correspondance Web.

Ces résultats décrivent un seul lot de données. Le traitement est un prototype ; les décisions sur les données restent à valider avec le métier.

1. Besoin et cahier des charges

Le P6 analyse prix, ventes, stocks et marges à partir de trois sources. Certaines étapes étaient difficiles à retracer. Je voulais pouvoir relancer les calculs, voir les produits écartés par les jointures et comprendre chaque alerte.

Ce que le traitement doit faire

Priorité	Attendu	Comment le vérifier
Essentiel	Lire les trois fichiers sans changer les originaux.	Message clair si un fichier ou une colonne manque.
Essentiel	Contrôler les clés et les jointures.	Nombre de produits trouvés et non trouvés dans le rapport.
Important	Signaler les valeurs à examiner et produire des exports.	Chaque alerte indique sa règle, sa valeur et le produit concerné.
Important	Comparer les résultats aux exports du P6.	Volumes et product_id comparés à df_final et df_clean.
Optionnel	Tester les prix atypiques.	Méthode, seuil et nombre d'alertes indiqués ; aucune suppression automatique.

Qui intervient

L'analyste prépare le lot, vérifie le rapport produit par le traitement et lit les alertes. Le référent e-commerce ou stocks décide si une donnée doit être corrigée. Le responsable technique serait à désigner si le prototype était repris dans un usage régulier.

Périmètre et suivi

Le travail couvre l'import local, les contrôles, les jointures, les calculs du P6 et les rapports. Il ne comprend pas de connexion directe à l'ERP ou au site, de mise à jour automatique des sources, ni de mise en production. Les classeurs source restent locaux et ne sont pas diffusés sur GitHub ; ils sont nécessaires pour refaire exactement les calculs.

Diagnostic, essais et documentation ont été réalisés sur le lot fourni entre le 24 et le 28 septembre 2026. Aucune durée de travail, aucun budget ni gain de temps n'a été mesuré. La veille Python des versions de pandas fonctionne depuis le 26 octobre ; la version 3.1.1 a été examinée le 9 novembre. Le contrôle automatique a été testé sur des copies du seul lot fourni, avec les mêmes exports que le lancement manuel. Aucun autre lot n'est disponible.

2. Essais et résultats

J'ai testé trois façons de rapprocher les mêmes fichiers ERP, Web et liaison. Chaque ligne du tableau décrit une méthode de traitement. Cette comparaison aide à comprendre pourquoi le code du P6 et ses exports ne donnent pas toujours les mêmes identifiants.

Méthode	Produits appariés	Après filtre marge	Ce que le test montre
Données d'origine	714	713	Garde les valeurs reçues ; mêmes product_id que les exports.
Méthode du notebook P6	713	712	Les corrections avant jointure donnent un résultat différent des exports.
Reconstitution des exports P6	714	713	Retrouve les identifiants et les libellés des exports enregistrés.

J'utilise la méthode Reconstitution des exports P6 pour comparer le POC aux anciens fichiers. Cette concordance ne prouve pas que les corrections d'identifiants sont justes pour l'entreprise.

Alertes relevées

Contrôle	Résultat sur ce lot
Références produits	Après harmonisation, deux produits portent le SKU 13127 ; 2 produits Web sont sans SKU.
Valeurs négatives	3 prix ERP, 2 stocks ERP et 2 ventes Web ; une marge de -634,99 %.
Stock	4 écarts de statut dans l'ERP, dont 3 produits appariés ; 25 mois de stock non calculables.
Prix atypiques	13 alertes par Z-score et 31 par IQR, dont 13 communes.

Les valeurs restent dans les données contrôlées. Le produit à marge négative est écarté de la vue analytique du P6 sur ce lot, comme dans l'export historique. Une alerte n'est pas une erreur confirmée.

Choix des outils

Python et Pandas ont été testés sur les classeurs et retenus : ils suffisent ici pour lire les fichiers, contrôler les jointures et produire les rapports. Z-score et IQR servent seulement à repérer des prix à revoir. Great Expectations, Polars et dbt ont été étudiés dans leurs documentations, mais pas testés sur ce lot ; aucun avantage de vitesse ou de qualité n'a été mesuré.

3. Choix et veille

J'ai comparé les options selon six critères. Les résultats concernent le lot testé ; je ne présente pas les outils non essayés comme de meilleures solutions.

Critère	Ce que j'ai vérifié ou décidé
Qualité	Les contrôles montrent les clés, les jointures et les valeurs à revoir. Retrouver 714 produits ne valide pas toutes les colonnes.
Biais	Les 111 produits sans Web restent comptés. Le filtre de marge et les seuils statistiques changent le résultat de l'analyse.
Temps	Aucun temps avant/après ni test de vitesse n'a été mesuré. Je ne chiffre aucun gain.
Reproductibilité	Même lot, mêmes exports en manuel et en automatique. Aucun autre lot disponible pour vérifier d'autres données.
Sécurité	Le traitement est local, les sources sont conservées et les sorties sont séparées. Les règles de partage restent à définir.
Conformité	Aucune correction automatique. Les règles métier et les droits de diffusion doivent être validés avant un usage régulier.

Comment j'ai fait la veille

J'ai privilégié les documentations officielles, en regardant si l'information répondait au besoin, si l'outil pouvait être utilisé sur ces fichiers et ce qu'il coûterait à maintenir. Les documentations techniques ont été consultées le 24 septembre 2026 ; les pages WooCommerce et GS1 ont été revues le 21 octobre 2026.

Pandas a servi aux jointures et aux contrôles. Les documentations de WooCommerce et de GS1 ont aidé à formuler des questions sur les produits et les stocks ; elles ne remplacent pas une règle validée par l'entreprise. Great Expectations, Polars et dbt ont été étudiés, sans essai comparatif sur les classeurs.

Un exemple de décision issue de la veille

Le 25 septembre 2026, j'ai lu les notes de Pandas 3.0.6, puis celles de 3.1.0 le 26 octobre et de 3.1.1 le 9 novembre. Le projet utilise Pandas 3.0.1. Les corrections de 3.1.1 concernent surtout la série 3.1 ; je n'ai pas identifié de changement qui impose un test immédiat sur le P13. Avant toute mise à jour, je relancerais la lecture Excel, les contrôles et la comparaison des exports.

Depuis le 26 octobre, un script Python consulte les versions stables chaque lundi à 12 h via le Planificateur Windows. Le contrôle du 9 novembre a repéré la version 3.1.1 ; ses notes ont été lues et la version a été marquée comme examinée. Je consulte la trace et je lis les notes officielles des versions à examiner. Le contrôle local demande que le PC soit allumé et la session ouverte ; il ne met pas les dépendances à jour.

Je garde un traitement local avec Pandas, déjà présent dans le P6, car aucun autre outil n'a montré un bénéfice sur ce lot. Je ne revendique pas d'économie d'énergie : elle n'a pas été mesurée.

4. Portfolio documentation et accompagnement

Portfolio professionnel

Le README d'accueil s'adresse aux recruteurs et aux responsables métier : il présente mon parcours et met en avant le projet hospitalier, le P5, le P12 et le P8. Chaque projet prioritaire renvoie vers une preuve consultable. La page VEILLE.md montre les sources consultées, les méthodes repérées et les décisions prises pour Bottleneck.

Preuves présentées	Compétences visibles
P5 et P8	Requêtes SQL, modélisation et transformation des données.
P4, P9 et P11	Préparation, analyse et présentation de données avec Python.
P10 et projet hospitalier	Analyse et présentation des résultats dans Power BI.
P12	Modélisation prédictive et script de prédiction. Projet validé.
P13	Amélioration d'un traitement et contrôle qualité. Évaluation à venir.

Le portfolio présente neuf projets : sept projets de formation validés, le P13 en attente d'évaluation et un projet personnel d'analyse hospitalière.

Suivi du projet

Diagnostic, essais et documentation du POC : réalisés du 24 au 28 septembre 2026. README et page de veille : en place au 21 octobre. Veille pandas programmée depuis le 26 octobre ; version 3.1.1 examinée le 9 novembre sans mise à jour du projet. Le contrôle automatique a traité des copies du seul lot fourni ; ses trois CSV sont identiques à ceux du lancement manuel avec la méthode Données d'origine (raw). Aucun autre lot n'est disponible. Relecture finale des livrables : en cours avant l'évaluation. Les durées et le budget ne sont pas connus.

Procédure pour garder des résultats fiables

1. Conserver les fichiers reçus, puis travailler sur des copies dans un dossier d'entrée identifié.

2. Placer les copies de erp.xlsx, liaison.xlsx et web.xlsx dans un sous-dossier de lots_a_traiter. Le contrôle programmé chaque jour à midi crée un dossier de résultats pour chaque nouveau lot complet. Le pipeline peut aussi être lancé directement dans VS Code.

3. Lire rapport_qualite.json et anomalies_poc.csv. Comparer les résultats aux exports manuels lors d'un test ou au lot précédent si un nouvel export devient disponible.

4. Pour chaque décision, noter le lot, le produit, l'alerte, la justification et la personne qui l'a validée. Si une règle change, mettre à jour le code et les explications.

Aider les utilisateurs à prendre l'outil en main

La mini-formation prévue part d'une alerte concrète. Je montre où déposer les fichiers, comment retrouver le rapport et le produit concerné, puis comment distinguer un fait mesuré d'une hypothèse. Le référent métier décide de l'action à prendre ; je documente son arbitrage. Ce support n'a pas encore été utilisé lors d'une séance réelle.

Les étapes sont écrites en langage courant et les alertes ne dépendent pas seulement d'une couleur. Le support prévoit une démonstration au clavier et des adaptations selon les besoins des participants. Le texte du PDF est sélectionnable ; les titres et les tableaux sont balisés pour faciliter la lecture avec les aides techniques.

5. IA limites et preuves

Usage de l'IA

L'IA m'a aidé à cadrer le travail, chercher des sources, structurer le code et clarifier les textes. Voici deux questions reformulées pour montrer ce que j'ai ensuite vérifié :

Question représentative	Vérification humaine
Compare les résultats du POC aux exports df_final et df_clean.	J'ai contrôlé les volumes, les product_id et les écarts dans les fichiers et les rapports.
Quelles limites faut-il retenir avant de conclure ?	J'ai vérifié les alertes et limité les conclusions au lot étudié.

Ces formulations ne sont pas l'historique complet des échanges. Le code a été exécuté sur les classeurs et les résultats ont été relus. L'IA ne décide pas si une valeur est correcte pour l'entreprise.

Ce qui reste à valider

- Le coefficient de TVA 1,2 et les formules viennent du P6 ; aucun audit comptable n'a été mené.
- Le contrôle peut se lancer automatiquement quand un lot complet est déposé et que le PC est allumé. Il produit des fichiers à examiner, sans envoyer de message ni corriger les données. La revue et les décisions restent humaines. Il a été testé sur des copies du seul lot disponible ; son comportement sur d'autres données n'est pas vérifié.
- Aucun gain de temps, de vitesse ou d'énergie n'a été mesuré. Les règles de partage des données restent à établir.

Fichiers à consulter

Dans le dossier P13 : notebooks/P6_Bottleneck_ameliore_finalise.ipynb, src/pipeline.py, src/quality_checks.py, src/auto_controle.py, src/veille_pandas.py, output/veille_pandas_state.json, outputs/, comparaison_options.md et suivi_et_documentation.md. À la racine : README.md pour le portfolio et VEILLE.md pour les sources et décisions.

Principales sources consultées

- Pandas — jointures et données manquantes : pandas.pydata.org/docs/
- Pandas — notes des versions 3.0.6, 3.1.0 et 3.1.1 : pandas.pydata.org/docs/whatsnew/
- Pandas — annonces de versions : github.com/pandas-dev/pandas/releases
- WooCommerce — produits et stocks : woocommerce.com/document/
- GS1 — identifiants : ref.gs1.org/standards/gtin-management/